



Московский государственный технический университет
Факультет ИУ «Информатика и системы управления»
Кафедра ИУ-1 «Системы автоматического управления»

ОТЧЕТ

Лабораторная работа №4

по дисциплине

«Эргатические системы»

Выполнил: Раков А.В.

Группа: ИУ1-41М

Проверил: Кучин А.С.

Работа выполнена: 21/05/2026

Отчет сдан: 21/05/2026

Оценка:

Цель работы:

Целью лабораторной работы является разработка системы автоматической классификации электроэнцефалографических (ЭЭГ) сигналов для выявления эпилептических приступов. Для достижения этой цели необходимо:

- Сформировать обучающую выборку из базы данных CHB-MIT (не менее 50 записей с приступами и 50 без приступов).
- Преобразовать временные ряды ЭЭГ в изображения с помощью непрерывного вейвлет-преобразования
- Построить и обучить сверточную нейронную сеть для бинарной классификации (приступ / без приступа).
- Сохранить обученную модель и оценить её эффективность на тестовой выборке.

Дополнительной задачей является автоматизация всего пайплайна: от загрузки EDF-файлов до генерации отчета с метриками.

Результаты:

В ходе выполнения работы была сформирована обучающая выборка на основе базы данных CHB-MIT (пациент chb08). Для этого использовались пять EDF-файлов с приступами, информация о временных интервалах приступов была взята из файла chb08-summary.txt. Также были задействованы пятнадцать файлов без приступов. На первом этапе каждый ЭЭГ-сигнал подвергался предобработке: усреднение по всем каналам и низкочастотная фильтрация с частотой среза 60 Гц для подавления высокочастотных помех. Далее из обработанного сигнала выделялись неперекрывающиеся сегменты длительностью 2 секунды. При частоте дискретизации 256 Гц каждый сегмент содержал 512 отсчетов. В результате удалось получить 400 сегментов, относящихся к эпилептическим приступам, и 400 сегментов без приступов. Таким образом, требование задания (не менее 50 образцов каждого класса) выполнено с большим запасом.

Для каждого сегмента с помощью непрерывного вейвлет-преобразования с вейвлетом Морле было построено частотно-временное представление – вейвлет-изображение. Использовались шкалы от 1 до 47. Полученный спектр коэффициентов нормировался, переворачивался по вертикали, масштабировался до размера 224×224 пикселя и преобразовывался в RGB-изображение. Визуальный анализ показал, что изображения, соответствующие приступам, содержат более выраженные высокочастотные компоненты и характерные всплески энергии по сравнению с изображениями фоновой активности. Все сгенерированные изображения были сохранены в две отдельные папки: seizure – для приступов и non_seizure – для фоновой активности.

Архитектура сверточной нейронной сети включала три сверточных блока, каждый из которых состоял из слоя свертки с ядром 3×3 и $\text{padding}=1$, пакетной нормализации, функции активации ReLU и слоя максимального пулинга с окном 2×2 . Количество фильтров в блоках составляло 32, 64 и 64 соответственно. После сверточных блоков следовал полносвязный слой с 128 нейронами, слой dropout с вероятностью отключения 0.5 и выходной слой с одним нейроном. В качестве функции потерь использовалась бинарная кросс-энтропия с логитами, оптимизатор – Adam с коэффициентом скорости обучения 0.001 и регуляризацией L2 (weight decay $1e-4$). Для увеличения разнообразия данных во время обучения применялась аугментация: горизонтальное отражение и изменение яркости с коэффициентом от 0.9 до 1.1.

Все данные были разделены на три выборки: обучающую (512 изображений, 64% от общего объема), валидационную (128 изображений, 16%) и тестовую (160 изображений, 20%). Обучение проводилось в течение 80 эпох. В процессе обучения наилучшая модель сохранялась по минимальному значению функции потерь на валидационной выборке. После завершения обучения модель была оценена на тестовой выборке. Достигнута общая точность 65.0%. Чувствительность (recall) для класса «приступ» составила 73.8%, а точность (precision) – 62.8%. Матрица ошибок показала, что из 80 истинных примеров без приступа модель правильно классифицировала 45, ошибочно отнесла к приступам 35; из 80 истинных примеров с приступом правильно распознано 59, пропущено 21. Таким образом, модель демонстрирует умеренную эффективность, причем чувствительность выше точности, что является предпочтительным для медицинской диагностики, поскольку пропуск приступа опаснее ложной тревоги.

В результате работы также были сохранены веса лучшей модели в файл `best_model.pth`, полный снапшот модели с историей обучения – в `eeg_cnn_model.pth`, а метрики в формате JSON – в `evaluation_results.json`. Папки с вейвлет-изображениями содержат по 400 файлов в формате PNG каждая. Таким образом, все этапы задания выполнены: сформирована выборка, построены вейвлет-изображения, разработана, обучена и сохранена сверточная нейронная сеть для классификации ЭЭГ на записи с приступом и без приступа.

Вывод:

В ходе выполнения лабораторной работы был реализован полный конвейер классификации ЭЭГ-сигналов при эпилепсии:

Успешно сформирована выборка из 800 сегментов (по 400 на каждый класс), что более чем в 8 раз превышает минимальное требование задания (50+50). Это обеспечило устойчивость обучения.

Вейвлет-преобразование позволило наглядно представить временные ряды в частотно-временной области. Полученные изображения сохранили диагностически значимые паттерны (пики, спайки), различимые между классами.

Разработанная CNN достигла точности 65% на тестовой выборке. Чувствительность (Recall) для класса «приступ» составила 73.8% – это важно, так как пропуск приступа критичнее ложной тревоги. Однако точность (Precision) 62.8% указывает на значительное количество ложноположительных срабатываний.

Факторы, ограничивающие качество:

- Использование усредненного сигнала (потеря информации с отдельных каналов).
- Ограниченный размер обучающей выборки (всего 800 изображений после увеличения).

Простая архитектура CNN без предобучения (transfer learning).

Пути улучшения:

- Добавить многоканальную обработку ЭЭГ (например, 3–5 ключевых отведений).
- Использовать предобученные модели (ResNet, EfficientNet) на сгенерированных вейвлет-изображениях.
- Применить более сложные методы аугментации (вращение, сдвиг по частоте).
- Увеличить объем данных за счет других пациентов базы CHB-MIT.

Тем не менее, поставленная задача решена в полном объеме: создан рабочий прототип, генерирующий вейвлет-изображения, обучающий CNN и сохраняющий модель для дальнейшего использования. Достигнутое качество (65% ассигасу) превышает уровень случайного угадывания (50%) и может служить базовым уровнем для более сложных архитектур.