



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ

ИУ «Информатика и системы управления»

КАФЕДРА

ИУ-1 «Системы автоматического управления»

ОТЧЕТ ПО ЗАДАНИЮ №4

Студент

ИУ1-41М

(Группа)

22/04/2026

(Подпись, дата)

Е.А. Букин

(И.О. Фамилия)

Преподаватель

22/04/2026

(Подпись, дата)

А.С. Кучин

(И.О. Фамилия)

2026 г.

Цель работы

Классифицировать временные ряды электроэнцефалографии (ЭЭГ) на записи во время эпилептического приступа и в его отсутствие. Ключевые навыки: применение свёрточных нейронных сетей к сложным временным рядам, представленным в частотно-временной области через вейвлет-скалограммы.

Ссылка на датасет: <https://physionet.org/content/chbmit/1.0.0/chb08/>

Результаты экспериментов

Задание 1: Загрузка данных и сегментация ЭЭГ

Использован открытый набор CHB-MIT Scalp EEG Database (Бостонская детская больница), подкаталог chb08 – 21 запись пациентки 3,5 лет с фокальной эпилепсией; запись 23 канала по схеме 10–20 с частотой дискретизации 256 Гц. По текстовому файлу chb08-summary.txt автоматически определены интервалы приступов в каждой записи. Из пяти файлов с приступами скачаны три первых (chb08_02.edf, chb08_05.edf, chb08_11.edf, ≈ 121 МБ) – этого достаточно для формирования требуемой выборки.

Извлечённые интервалы приступов: chb08_02.edf – 2670...2841 с (171 с); chb08_05.edf – 2856...3046 с (190 с); chb08_11.edf – 2988...3122 с (134 с). В каждой записи 23 канала усреднены в один сигнал, к которому применён ФНЧ 60 Гц с нулевой фазовой задержкой (FIR-фильтр) – для подавления сетевой наводки и мышечных артефактов.

Сигнал нарезан на непересекающиеся окна длиной 4 с (1024 отсчёта при 256 Гц). Метка окна: «приступ» – если все отсчёты внутри размеченного интервала, «норма» – если ни один. Граничные окна (с частичным попаданием) отбрасывались, чтобы не вносить шум в метки.

Задание 2: Формирование сбалансированной обучающей выборки

Из трёх файлов получено 122 окна с приступом ($42 + 47 + 33$) и 2574 окна без приступа. Класс «норма» сильно превалирует – это естественно, ведь приступ занимает лишь несколько минут от часа записи. Для устранения дисбаланса проведена случайная балансировка: оставлено по 60 окон каждого класса (с фиксированным random seed для воспроизводимости). Итог – 120 сегментов, превышающий заданный минимум в 50 окон каждого класса.

Задание 3: Построение вейвлет-скалограмм

Для каждого 4-секундного окна выполнено непрерывное вейвлет-преобразование (CWT) с комплексным вейвлетом Морле `cmor1.5-1.0`. Шкалы пересчитаны в частоты по соотношению $f = f_c \cdot f_s / s$; взято 80 логарифмически распределённых частот в диапазоне 1–60 Гц, покрывающем все физиологически значимые ритмы – дельта (1–4 Гц), тета (4–8 Гц), альфа (8–13 Гц), бета (13–30 Гц) и нижнюю гамму (30–60 Гц).

Из коэффициентов вычислена мощность $|\text{coef}|^2$ и переведена в децибелы. Чтобы все 120 изображений были в одной цветовой шкале, заранее по всему пулу сегментов оценены глобальные пороги – 1-й и 99-й процентиля дБ-мощности ($V_{\text{MIN}} \approx -119,8$ дБ; $V_{\text{MAX}} \approx -72,3$ дБ). Каждая скалограмма обрезается по $[V_{\text{MIN}}; V_{\text{MAX}}]$, нормируется в $[0; 1]$ и раскрашивается перцептивно равномерной палитрой `magma`; результат сохраняется как PNG-изображение размера 64×64 в папку `images/seizure/` или `images/normal/`. Итого получено 120 файлов: 60 «приступ» + 60 «норма».




Рис. 1. Примеры вейвлет-скалограмм для обоих классов: верхний ряд – приступ, нижний – норма

На скалограммах класса «приступ» отчётливо видны устойчивые яркие полосы в полосе 1–10 Гц и общая повышенная насыщенность изображения по сравнению с нормой. Сегменты класса «норма» выглядят более «зернистыми», энергия распределена менее когерентно. Это подтверждает, что выбранное частотно-временное представление действительно несёт классификационно-значимую информацию.

Задание 4: Архитектура свёрточной нейронной сети

Построена компактная CNN на Keras (TensorFlow 2.21). Архитектура – три последовательных блока «Conv2D + ReLU + MaxPooling» с числом фильтров $16 \rightarrow 32 \rightarrow 64$ (ядро 3×3 , паддинг same, пуллинг 2×2), затем Flatten, два полносвязных слоя ReLU (64 и 32 нейрона) с Dropout 0,5 для регуляризации и финальный нейрон с сигмойдой, выдающий вероятность класса «приступ». На входе слой Rescaling нормирует пиксели к диапазону $[0; 1]$. Общее число обучаемых параметров – 287 905 ($\approx 1,1$ МБ). Глубже сеть делать нецелесообразно: при 120 примерах она быстро переобучилась бы.

Оптимизатор – Adam ($lr = 1 \cdot 10^{-3}$), функция потерь – бинарная кросс-энтропия, метрика – ассигасу. Размер батча 16, до 50 эпох.

Задание 5: Обучение

Выборка из 120 изображений случайно разбита на обучающую, валидационную и тестовую части в пропорции 60 / 20 / 20 со стратификацией по классу: 76 / 20 / 24 примера соответственно. Для борьбы с переобучением подключён EarlyStopping с $patience = 6$ по val-loss и восстановлением весов лучшей эпохи. Обучение фактически остановилось примерно на 35-й эпохе.




Рис. 2. Кривые обучения: функция потерь (слева) и точность (справа)

Кривые потерь устойчиво снижаются и сходятся; train- и val-loss идут параллельно, без расходящегося отрыва, характерного для переобучения. Точность на валидации стабилизируется на уровне $\approx 0,85\text{--}0,95$. Это типичная картина для удачной по объёму архитектуры на небольшом датасете.

Задание 6: Оценка качества на тестовой выборке

Тестовая выборка (24 изображения, по 12 каждого класса) ни при обучении, ни при ранней остановке не использовалась – это даёт несмещённую оценку обобщающей способности. На тесте достигнуто: ассигасу = 0,958, loss

= 0,173. Метрики по классам: «норма» – precision 0,923, recall 1,000, F1 = 0,960; «приступ» – precision 1,000, recall 0,917, F1 = 0,957.



Рис. 3. Матрица ошибок на тестовой выборке

Из 24 тестовых примеров неверно классифицирован только один – приступ, ошибочно отнесённый к норме (false negative). Ложноположительных срабатываний нет – все 12 «норма»-примеров определены верно. Для медицинского применения такая ошибка наименее желательна, однако объём тестовой выборки невелик и единичный промах попадает в пределы статистической вариативности.

Задание 7: Сохранение модели и проверка её работы

Обученная модель сохранена в файл `eeg_cnn_model.keras` (новый одноархивный формат Keras, 3,35 МБ; содержит и архитектуру, и веса). Для контроля проведена обратная загрузка модели функцией `load_model` и поэлементное сравнение весов с исходным объектом – все веса совпали бит-в-бит. Это подтверждает, что сохранённый файл полностью самодостаточен и пригоден к использованию вне обучающего окружения.

Загруженная модель прогнана на шести случайных тестовых примерах; для каждого выведена истинная метка и предсказание с вероятностью.




Рис. 4. Демонстрация работы загруженной модели на тестовых примерах

Все шесть примеров классифицированы верно, причём вероятности для большинства из них уверенно близки к 0 или 1, что говорит о чёткой разделимости классов в выученном признаковом пространстве.

Вывод

В работе реализован полный пайплайн классификации ЭЭГ для определения эпилептических приступов на материале CHB-MIT (chb08): автоматическая загрузка трёх EDF-файлов, парсинг summary, усреднение каналов, ФНЧ 60 Гц, нарезка на 4-секундные окна и сборка сбалансированной выборки из 120 сегментов (по 60 каждого класса – выше заданного минимума 50).

Каждое окно переведено в вейвлет-скалограмму с комплексным Морле в диапазоне 1–60 Гц и сохранено как изображение 64×64 в отдельных папках по классам. На полученных изображениях обучена компактная CNN (3 свёрточных блока + полносвязная голова с Dropout); EarlyStopping по val-loss обеспечил выбор лучшей эпохи.

На независимой тестовой выборке достигнута accuracy 0,958 при $F1 \approx 0,96$ для обоих классов; единственная ошибка – один false negative из 24 примеров. Модель сохранена в формате .keras, повторно загружена, веса совпали бит-в-бит, на демонстрационных примерах сеть уверенно отделяет приступ от нормы. Таким образом, частотно-временное представление сигнала в виде вейвлет-скалограммы в сочетании со свёрточной сетью является эффективным подходом к задаче автоматического выявления эпилептических приступов на ЭЭГ.