



Московский государственный технический университет
Факультет ИУ «Информатика и системы управления»
Кафедра ИУ-1 «Системы автоматического управления»

ОТЧЕТ
по лабораторной работе №4
по дисциплине
«Эргатические системы»

Выполнил: Чжу Цзыюй

Группа: ИУ1И-41М

Проверил: Андриков Д. А.

Работа выполнена: 07/04/2026

Отчет сдан: 07/04/2026

Оценка:

1. Введение

Цель работы – создание системы бинарной классификации ЭЭГ (наличие / отсутствие эпилептического приступа) с использованием непрерывного вейвлет-преобразования и свёрточной нейронной сети (CNN). Одномерные сигналы ЭЭГ преобразуются в двумерные спектральные изображения (скалограммы), которые затем подаются на вход CNN.

Источник данных – открытая база CHB-MIT (PhysioNet), содержащая длительные ЭЭГ-записи пациентов с эпилепсией. Для анализа выбран один пациент (chb08). Сформирована сбалансированная выборка из 100 скалограмм: 50 для класса «приступ», 50 для класса «норма».

2. Используемые данные

2.1 Параметры сигналов

- Частота дискретизации: 256 Гц.
- Каналов: 23 (система 10-20). В исходных файлах присутствовало дублирование имени «T8-P8»; при загрузке через MNE дубликаты автоматически переименованы (T8-P8-o, T8-P8-i).
- Рабочий канал: **FP1-F7** (лобно-височное отведение, чувствительное к височной эпилепсии).
- Длина одного сегмента: 10 секунд (2560 отсчётов).

2.2 Используемые файлы

Файлы с приступами (5):

chb08_02.edf , chb08_05.edf , chb08_11.edf , chb08_13.edf , chb08_21.edf

В каждом файле зафиксирован один приступ. Суммарная длительность приступных интервалов ≈ 919 с, что позволило извлечь 50 непересекающихся сегментов.

Файлы без приступов (2):

chb08_03.edf , chb08_04.edf


3. Методика

3.1 Предобработка и формирование набора изображений

1. Из каждого файла с приступом внутри размеченных границ случайно извлечено до 10 отрезков по 10 с.

2. Из нормальных файлов отрезки выбираются случайным образом, избегая зон, прилегающих к приступам.
3. Для каждого отрезка выполнено непрерывное вейвлет-преобразование с комплексным вейвлетом Морле (cmor1.5-1.0) на масштабах, покрывающих диапазон частот $\sim 0.5\text{--}30$ Гц (основные ритмы ЭЭГ).
4. Вычислена спектральная плотность мощности. Полученные данные визуализированы в виде цветных скалограмм размером 224×224 пикселей.

Примеры скалограмм для обоих классов приведены на **Рисунке 1**.



3.2 Архитектура свёрточной нейронной сети

Используется трёхслойная CNN с последовательным увеличением числа фильтров:

- Вход: одноканальное изображение 224×224 (оттенки серого).
- Свёрточные блоки:
 - $\text{Conv2d}(1, 16, 3 \times 3) \rightarrow \text{ReLU} \rightarrow \text{MaxPool}(2 \times 2) \rightarrow 112 \times 112 \times 16$
 - $\text{Conv2d}(16, 32, 3 \times 3) \rightarrow \text{ReLU} \rightarrow \text{MaxPool}(2 \times 2) \rightarrow 56 \times 56 \times 32$
 - $\text{Conv2d}(32, 64, 3 \times 3) \rightarrow \text{ReLU} \rightarrow \text{MaxPool}(2 \times 2) \rightarrow 28 \times 28 \times 64$
- Классификатор:
 - Flatten $\rightarrow 64 \times 28 \times 28 = 50176$ нейронов
 - Полносвязный слой $50176 \rightarrow 128 + \text{ReLU} + \text{Dropout}(0.5)$
 - Выходной слой $128 \rightarrow 2$ (функция потерь Cross-Entropy включает softmax).

Всего обучаемых параметров: 6 446 210.


3.3 Процесс обучения

- Выборка разделена на обучающую (80 изображений) и тестовую (20 изображений) с фиксированным генератором случайных чисел (seed=42).
- Размер мини-пакета: 8.
- Функция потерь: Cross-Entropy Loss.
- Оптимизатор: Adam (learning rate = 0.001).
- Число эпох: 30.
- Регуляризация: Dropout с вероятностью 0.5.

4. Результаты

4.1 Динамика обучения

На **Рисунке 2** показаны кривые потерь и точности на обучающем множестве в ходе 30 эпох.



Потери монотонно снижаются, точность быстро растёт. С 20-й эпохи обучение выходит на плато, достигая 100% точности на обучающих данных. Несмотря на малый объём


выборки, Dropout позволил избежать явного переобучения.

4.2 Оценка на тестовой выборке

Точность на тестовых 20 изображениях составила **100.00 %**. Это свидетельствует о том, что модель полностью разделяет приступные и нормальные паттерны в рамках данного набора данных.

4.3 Визуализация предсказаний

На **Рисунке 3** представлены четыре тестовые скалограммы с истинными и предсказанными метками.



Все четыре примера классифицированы верно. Приступные скалограммы отличаются резким ростом мощности в диапазоне 2–10 Гц, тогда как нормальные сегменты содержат обычные фоновые ритмы.

5. Обсуждение

Использование вейвлет-скалограмм в паре с CNN позволило добиться идеальной классификации на данных одного пациента. Ключевые факторы успеха:

- Тщательный отбор неперекрывающихся сегментов.
- Выбор подходящего отведения (FP1-F7).
- Архитектура CNN с дропаутом, ограничивающая переобучение.

Ограничения:

- Данные только от одного пациента (chbo8) — обобщение на других пациентов невозможно без дообучения.
- Отсутствие кросс-валидации: оценка точности получена на одном разбиении.
- Малый объём выборки (100 изображений) при значительном числе параметров сети может приводить к переобучению, хотя на тесте этого не наблюдается.
- Не учитывались физиологические и аппаратные артефакты.

Перспективы:

- Добавление записей других пациентов и проведение кросс-валидации.
- Переход к многоканальному анализу (многомерные тензоры «время-частота-канал»).
- Применение аугментации (случайные сдвиги, добавление шума) для искусственного расширения выборки.

6. Выводы

Разработан сквозной пайплайн обработки ЭЭГ: от извлечения сегментов из EDF-файлов до построения скалограмм и обучения CNN.

Модель показала 100% точность на тестовой выборке, подтверждая эффективность вейвлет-визуализации для детекции эпилептических приступов на данных одного пациента.

Все материалы (скрипты, изображения, обученная модель) подготовлены для дальнейшего использования в учебных целях.

Приложение: использованное программное обеспечение

- Python 3.10
- MNE-Python (чтение EDF)
- PyWavelets (непрерывное вейвлет-преобразование)
- PyTorch и Torchvision (CNN и загрузка данных)

- Matplotlib (визуализация)

Все этапы работы воспроизводимы в среде Jupyter Notebook, код снабжён русскоязычными комментариями.