



Московский государственный технический университет
Факультет ИУ «Информатика и системы управления»
Кафедра ИУ-1 «Системы автоматического управления»

ОТЧЕТ

Лабораторная работа №5

по дисциплине

«Эргатические системы»

Выполнил: Раков А.В.

Группа: ИУ1-41М

Проверил: Кучин А.С.

Работа выполнена: 21/05/2026

Отчет сдан: 21/05/2026

Оценка:

Цель работы:

Целью работы является разработка и исследование полного пайплайна обработки электроэнцефалографических (ЭЭГ) сигналов для бинарной классификации моторного воображения – представления о сжатии левого или правого кулака.

Основные задачи:

- загрузить и проанализировать набор данных ЭЭГ;
- выполнить нормализацию временных рядов;
- преобразовать одномерные сигналы в частотно-временные изображения (скалограммы) с помощью непрерывного вейвлет-преобразования (CWT);
- обучить компактную сверточную нейронную сеть (CNN) для распознавания двух классов;
- оценить качество классификации на тестовой выборке.

Результаты:

Данные и предобработка

В ходе работы использовался набор данных, содержащий фрагменты ЭЭГ длиной 3000 отсчётов каждый. Обучающая выборка включала 400 образцов, из которых 200 относились к классу «левый кулак» (класс 0) и 200 – к классу «правый кулак» (класс 1). Тестовая выборка состояла из 320 образцов (по 160 каждого класса). Таким образом, распределение классов было полностью сбалансированным, что позволило использовать ассигасу как информативную метрику качества.

Перед дальнейшей обработкой каждый сигнал был нормализован отдельно: из каждого временного ряда вычиталось его среднее значение и результат делился на стандартное отклонение. Это позволило устранить влияние абсолютного масштаба амплитуды, который может варьироваться между разными записями.

Вейвлет-преобразование и скалограммы

Для каждого нормализованного сигнала было выполнено непрерывное вейвлет-преобразование (CWT) с использованием комплексного вейвлета Морле. Диапазон масштабов был выбран от 1 до 48. Полученные коэффициенты были преобразованы с помощью функции $\log_{1p}$ для сжатия динамического диапазона, а затем прорежены по временной оси с шагом 16. В результате для каждого исходного ЭЭГ-фрагмента была построена скалограмма – двумерное представление размером 48 (масштабов) на 188 (временных окон). Каждое такое изображение было дополнительно стандартизировано (центрировано и

приведено к единичной дисперсии), чтобы улучшить сходимость при обучении нейронной сети.

Визуальный анализ скалограмм показал, что образцы разных классов демонстрируют различия в распределении энергии по масштабам и времени. В частности, для класса «левый кулак» наблюдались более выраженные высокочастотные компоненты (малые масштабы) в определённые моменты, в то время как для класса «правый кулак» картина была иной. Это подтвердило принципиальную возможность различения двух состояний моторного воображения по частотно-временным паттернам.

Архитектура нейронной сети

Была разработана компактная свёрточная нейронная сеть, состоящая из трёх свёрточных блоков и полносвязного классификатора. На вход сеть принимала одноканальные скалограммы размером 48×188 . Первый свёрточный слой содержал 8 фильтров размером 3×3 с последующей активацией ReLU и субдискретизацией (максимальный пулинг 2×2). Второй слой содержал 16 фильтров, третий – 32 фильтра. После последнего свёрточного слоя применялся адаптивный средний пулинг до размера 4×4 , что обеспечило независимость выходного признакового пространства от точных размеров входного изображения. Далее следовал слой уплощения, полносвязный слой с 32 нейронами, активация ReLU, dropout с вероятностью 0.2 и выходной слой на два класса. Общее число обучаемых параметров составило менее 50 тысяч, что позволило избежать переобучения на ограниченном объёме данных.

Обучение модели

Обучение проводилось в течение 15 эпох с использованием функции потерь CrossEntropyLoss и оптимизатора Adam с шагом обучения 0.001. Размер мини-батча был установлен равным 32. На каждой эпохе вычислялись средние потери и точность на обучающей выборке.

В процессе обучения наблюдалось монотонное снижение значения функции потерь с начальных значений около 0.69 до финальных 0.38. Точность на обучении выросла с 52% на первой эпохе до 85% на последней. Такая динамика свидетельствовала о том, что модель успешно выявляет закономерности в скалограммах и не переобучается (разрыв между обучающей и тестовой точностью оставался умеренным).

Оценка качества на тестовой выборке

После завершения обучения модель была проверена на тестовой выборке, не участвовавшей в процессе настройки весов. Общая точность (ассигасу) составила 68,4%. Это значение заметно выше случайного уровня (50%) и

подтверждает, что вейвлет-представление несёт значимую информацию для различения воображаемых движений левой и правой руки.

Анализ ошибок показал, что из 160 образцов класса 0 (левый кулак) правильно распознаны 113, а 47 ошибочно отнесены к классу 1. Из 160 образцов класса 1 правильно распознаны 106, ошибочно – 54. Таким образом, полнота (recall) для класса 0 составила около 70,6%, для класса 1 – 66,2%. Точность (precision) для класса 0 – 67,7%, для класса 1 – 69,3%. Значения F1-меры для обоих классов оказались близки – около 0,69.

Полученные результаты свидетельствуют о том, что предложенный пайплайн (нормализация → SWT → компактная CNN) обеспечивает качество выше случайного, однако оставляет пространство для улучшений. Основными факторами, ограничивающими точность, являются малый объём обучающей выборки (всего 400 примеров) и высокая межиндивидуальная вариативность ЭЭГ-сигналов. Тем не менее, работа подтверждает принципиальную возможность использования вейвлет-скалограмм для классификации моторного воображения по одноканальной ЭЭГ.

Вывод:

В ходе лабораторной работы был реализован полный пайплайн обработки ЭЭГ-сигналов моторного воображения.

Преобразование временного ряда в скалограмму с помощью непрерывного вейвлет-преобразования позволяет получить наглядное частотно-временное представление, пригодное для анализа сверточными сетями.

Компактная CNN с тремя сверточными слоями и адаптивным пулингом успешно обучается на небольших датасетах и достигает точности ~68% на тестовой выборке, что значительно выше случайного угадывания.

Полученный результат подтверждает, что ЭЭГ-паттерны, связанные с воображением движения левой и правой руки, содержат различимые признаки в частотно-временной области, однако для повышения качества требуется либо больше данных, либо использование более сложных методов обработки (например, пространственно-временных фильтров или ансамблей).

Предложенный пайплайн может быть масштабирован на многоклассовую классификацию (например, ноги, язык) или использован в системах мозг-компьютерного интерфейса.