



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ

Информатика и системы управления

КАФЕДРА

Системы автоматического управления

ОТЧЁТ
Задание №5

Дисциплина: «Эргатические системы»

Студент ИУ1И-41М

Дун Боян

преподаватель

А. С. Кучин

2026 г.

1. Цель работы

Цель работы — исследовать когнитивные характеристики мозга по данным ЭЭГ и построить нейросетевую модель для распознавания двух классов моторного воображения. В качестве исходного признакового представления используется временной сигнал ЭЭГ, который преобразуется в двумерное временно-частотное изображение с помощью вейвлет-преобразования.

2. Анализ требований задания

Согласно заданию №5 необходимо выполнить полный цикл анализа данных ЭЭГ: загрузить обучающую и тестовую выборки, описать экспериментальный контекст, выполнить вейвлет-преобразование временного сигнала и обучить нейронную сеть для двухклассовой классификации.

№	Требование задания	Как реализовано в Notebook
1	Загрузить обучающую и тестовую выборки, а также target-файлы.	В коде определены четыре файла: MI-EEG-B9T.csv, 2class_MI_EEG_train_9.csv, MI-EEG-B9E.csv, 2class_MI_EEG_test_9.csv. Чтение выполняется через <code>pandas.read_csv(header=None)</code> .
2	Описать эксперимент, по которому собран датасет.	В Markdown-блоке Notebook описан набор EEG Motor Movement/Imagery Dataset: ЭЭГ-сигналы, моторное воображение, визуальные подсказки и классы движения.
3	Провести анализ датасета и преобразовать временной	Реализованы стандартизация <code>trial</code> , передискретизация сигнала до 256

	сигнал в изображение с помощью вейвлет-преобразования.	точек, Morlet CWT и построение scalogram-изображений.
4	Натренировать нейронную сеть для распознавания когнитивной характеристики.	Используется MLPClassifier с двумя скрытыми слоями 128 и 64 нейрона, функцией ReLU, оптимизатором Adam и early stopping.

3. Описание исходных данных

В лабораторной работе использованы подготовленные CSV-файлы, основанные на EEG Motor Movement/Imagery Dataset. Каждая строка в файле признаков соответствует одному EEG-образцу или trial, а каждый столбец — отдельной временной точке сигнала. Целевой признак задаёт принадлежность образца к одному из двух классов моторного воображения.

Файл	Назначение	Размерность по результатам Notebook
MI-EEG-B9T.csv	Обучающая выборка ЭЭГ-сигналов	400 × 3000
2class_MI_EEG_train_9.csv	Метки обучающей выборки	400
MI-EEG-B9E.csv	Тестовая выборка ЭЭГ-сигналов	320 × 3000
2class_MI_EEG_test_9.csv	Метки тестовой выборки	320

Распределение классов является сбалансированным: в обучающей выборке содержится 200 объектов класса 0 и 200 объектов класса 1; в тестовой выборке — 160 объектов класса 0 и 160 объектов класса 1. Это важно, так как ассигуру в

таком случае можно использовать как базовую метрику качества без сильного смещения из-за дисбаланса классов.




Рисунок 1 — Примеры исходных временных рядов ЭЭГ для двух классов.

4. Предобработка и вейвлет-преобразование

Поскольку ЭЭГ является нестационарным сигналом, его форма и спектральный состав могут изменяться во времени. Поэтому для анализа используется вейвлет-преобразование, которое позволяет получить карту “время — масштаб” и представить каждый trial в виде двумерного изображения.

Этап	Содержание
Стандартизация trial	Для каждого временного ряда отдельно вычисляются среднее и стандартное отклонение; затем применяется z-score нормализация.
Передискретизация	3000 временных отсчётов уменьшаются до 256 точек с помощью линейной интерполяции. Это снижает вычислительную нагрузку.
Morlet CWT	Для масштабов 2, 4, ..., 32 выполняется свёртка с комплексным Morlet-вейвлетом.
Логарифмирование амплитуд	Используется $\log_{10}$ для сжатия динамического диапазона значений вейвлет-карты.

После преобразования размерность обучающего массива становится $400 \times 16 \times 256$, а тестового — $320 \times 16 \times 256$. Здесь 16 — число масштабов вейвлета, 256 — длина сигнала после передискретизации.




Рисунок 2 — Пример вейвлет-изображения для класса 0.




Рисунок 3 — Пример вейвлет-изображения для класса 1.

5. Формирование признаков для нейронной сети

В коде вейвлет-изображения не подаются напрямую в сверточную нейронную сеть. Вместо этого каждое изображение размером 16×256 разворачивается в одномерный вектор длиной 4096. Затем к полученным признакам применяется StandardScaler.

Преобразование	Результат
Вейвлет-изображение одного объекта	16×256

Развёрнутый вектор признаков одного объекта	4096 признаков
Обучающие признаки после развёртывания	400×4096
Тестовые признаки после развёртывания	320×4096
Валидационная разбивка	320 объектов для обучения и 80 объектов для валидации

6. Архитектура и обучение модели

Для классификации используется многослойный перцептрон `MLPClassifier`. Это классическая полносвязная нейронная сеть, которая принимает вектор признаков и возвращает метку одного из двух классов.

Параметр	Значение в коде
Тип модели	<code>MLPClassifier</code>
Скрытые слои	<code>(128, 64)</code>
Функция активации	<code>ReLU</code>
Оптимизатор	<code>Adam</code>
Размер batch	<code>32</code>
Максимальное число итераций	<code>150</code>
Регуляризация alpha	<code>1e-4</code>
Контроль переобучения	<code>early_stopping=True,</code> <code>validation_fraction=0.15,</code> <code>n_iter_no_change=12</code>




Рисунок 4 — Кривая функции потерь при обучении MLP.

По кривой видно, что функция потерь быстро уменьшается уже в первые итерации. При этом дальнейший рост качества на валидационной части ограничен, что указывает на сложность задачи и возможный риск переобучения при малом числе обучающих объектов.

7. Результаты классификации

Качество модели оценивалось на валидационной и тестовой выборках. Основные метрики включают accuracy, precision, recall и F1-score.

Выборка	Accuracy	Macro F1	Комментарий
Валидационная	0.6375	0.6370	Качество выше случайного уровня, но остаётся умеренным.
Тестовая	0.6625	0.6617	Модель правильно классифицирует 212 из 320 тестовых объектов.

Класс	Precision	Recall	F1-score	Support
-------	-----------	--------	----------	---------

0	0.6477	0.7125	0.6786	160
1	0.6806	0.6125	0.6447	160
Macro avg	0.6641	0.6625	0.6617	320
Weighted avg	0.6641	0.6625	0.6617	320




Рисунок 5 — Матрица ошибок на тестовой выборке.

Матрица ошибок показывает, что для класса 0 корректно определено 114 объектов, а 46 ошибочно отнесены к классу 1. Для класса 1 корректно определено 98 объектов, а 62 ошибочно отнесены к классу 0. Следовательно, модель лучше распознаёт класс 0 по полноте recall, тогда как класс 1 чаще смешивается с классом 0.

8. Анализ качества и ограничений реализации

Аспект	Оценка
Соответствие заданию	Код выполняет основные требования: загружает данные, описывает эксперимент, строит

	вейвлет-изображения и обучает нейронную сеть.
Сильная сторона	Использование вейвлет-преобразования хорошо подходит для нестационарных ЭЭГ-сигналов, так как сохраняет информацию о времени и масштабе.
Ограничение	Вейвлет-изображения разворачиваются в одномерные векторы, поэтому пространственная структура изображения частично теряется.
Ограничение	Используется MLP, а не CNN. Для изображений scalogram сверточная сеть могла бы лучше учитывать локальные паттерны во времени и масштабе.
Ограничение	Точность около 66% показывает, что задача распознаётся лучше случайного уровня, но качество недостаточно высокое для практического применения без доработки.

Для улучшения результата можно увеличить число масштабов вейвлета, использовать более длинное временное представление, применить CNN для прямой обработки изображений, добавить регуляризацию, использовать кросс-валидацию, а также попробовать специализированные методы BCI-анализа, например CSP или filter bank CSP.

9. Выводы

- В работе выполнен анализ задания №5, связанного с исследованием когнитивных характеристик мозга по данным ЭЭГ.

- Исходные временные ряды ЭЭГ были преобразованы в вейвлет-изображения, которые отражают изменение амплитудных характеристик сигнала по времени и масштабу.
- На основе полученных признаков была обучена нейронная сеть MLP для двухклассовой классификации моторного воображения.
- На тестовой выборке получена accuracy 0.6625 и macro F1-score 0.6617, что подтверждает работоспособность предложенного подхода, но также показывает необходимость дальнейшей оптимизации модели.
- Наиболее перспективные направления улучшения — использование CNN для scalogram-изображений, настройка параметров вейвлета и применение специализированных методов обработки ЭЭГ.