



Московский государственный технический университет
Факультет ИУ «Информатика и системы управления»
Кафедра ИУ-1 «Системы автоматического управления»

ОТЧЕТ

Задание №5

по дисциплине

«Эргатические системы»

Выполнил: Мэди Гадир

Группа: ИУ1и-41М

2026 г

Аннотация

Исследование когнитивных характеристик мозга по данным ЭЭГ. Основная задача – загрузка временных рядов ЭЭГ, преобразование сигналов в частотно-временные изображения (скалограммы) с помощью вейвлет-преобразования и обучение свёрточной нейронной сети (CNN) для бинарной классификации воображаемых движений (сжатие левого или правого кулака).

1. Введение

Электроэнцефалография (ЭЭГ) является одним из наиболее распространённых методов исследования мозговой активности, позволяющим неинвазивно регистрировать электрические сигналы мозга. В последние годы значительный интерес вызывает применение методов машинного обучения, в частности свёрточных нейронных сетей (CNN), для анализа ЭЭГ-данных в задачах интерфейса «мозг–компьютер». Одной из ключевых задач является распознавание воображаемых движений (например, сжатие левого или правого кулака) по ЭЭГ-сигналам.

Цель данной работы – разработать и обучить модель глубокого обучения, способную классифицировать воображаемые движения на основе временных рядов ЭЭГ, предварительно преобразованных в частотно-временные изображения (скалограммы) с помощью непрерывного вейвлет-преобразования (CWT).

1. Описание данных

В работе использован открытый датасет **EEG Motor Movement/Imagery Dataset** (доступный на PhysioNet). Данные содержат записи ЭЭГ, полученные от здоровых испытуемых во время выполнения реальных и воображаемых движений. В рамках данной лабораторной работы используется подмножество, включающее только два класса: воображение сжатия левого кулака и воображение сжатия правого кулака.

Характеристики выборки:

- **Тренировочная выборка (сигналы):** MI-EEG-B9T.csv – 400 строк, каждая строка содержит временной ряд длиной 3000 отсчётов (одноканальная ЭЭГ или один канал после предобработки).
- **Тестовая выборка (сигналы):** MI-EEG-B9E.csv – 320 строк, аналогичная размерность (320×3000).
- **Целевые метки:** два отдельных CSV-файла (2class_MI_EEG_train_9.csv и 2class_MI_EEG_test_9.csv) с бинарными значениями (0 – левый кулак, 1 – правый кулак).

Перед подачей в модель все сигналы были стандартизированы с помощью `StandardScaler` (вычитание среднего и деление на стандартное отклонение по каждому сигналу). Это необходимо для устранения дрейфа базовой линии и приведения амплитуд к единому масштабу.

2. Методология обработки и архитектура модели

2.1. Вейвлет-преобразование и генерация скалограмм

Для преобразования одномерного сигнала в двумерное частотно-временное представление использовано **непрерывное вейвлет-преобразование (CWT)** с материнским вейвлетом **Morlet** (тип `cmor`). Диапазон масштабов выбран от 1 до 32. Для каждого сигнала были вычислены коэффициенты CWT, взяты их модули, и выполнена нормализация каждого изображения в диапазон $[0,1]$ (по формуле $(img - min)/(max - min + eps)$).

Результирующие скалограммы имеют размерность:

- **Обучающая выборка:** (400, 32, 3000, 1) – 400 изображений, 32 масштаба, 3000 временных отсчётов, 1 канал.
- **Тестовая выборка:** (320, 32, 3000, 1).




рис1 – пример скалограммы: ось X – время, ось Y – масштаб, цвет – нормализованная амплитуда

2.2. Архитектура свёрточной нейронной сети

Разработана CNN, состоящая из двух свёрточных блоков и полносвязной части. Основные параметры приведены в таблице ниже.

СЛОЙ	ВЫХОДНАЯ РАЗМЕРНОСТЬ	КОЛИЧЕСТВО ПАРАМЕТРОВ
CONV2D (32 ФИЛЬТРА, 3×3)	(32, 3000, 32)	320
MAXPOOLING2D (2×2)	(16, 1500, 32)	0
DROPOUT (0.3)	(16, 1500, 32)	0
CONV2D (64 ФИЛЬТРА, 3×3)	(16, 1500, 64)	18 496
MAXPOOLING2D (2×2)	(8, 750, 64)	0
DROPOUT (0.3)	(8, 750, 64)	0
FLATTEN	384 000	0
DENSE (128)	128	49 152 128
DROPOUT (0.5)	128	0
DENSE (1, SIGMOID)	1	129

Итого обучаемых параметров: ≈ 49.15 млн.

Модель компилировалась с оптимизатором **Adam** (скорость обучения 0.001), функцией потерь **binary_crossentropy** и метрикой **accuracy**.

3. Результаты эксперимента

Обучение проводилось в течение 50 эпох с размером пакета 32. Для предотвращения переобучения использовался **ранний останов (EarlyStopping)** с мониторингом `val_accuracy`, терпением 8 эпох и восстановлением лучших весов.

Динамика обучения (ключевые эпохи):

ЭПОХА	ТОЧНОСТЬ НА ОБУЧЕНИИ	ТОЧНОСТЬ НА ВАЛИДАЦИИ
1	48.5%	59.1%
6	60.3%	71.9%
11	72.5%	77.5% (максимум)
16	81.0%	76.6%
19	84.0%	71.3% (останов)

Наибольшая точность на валидационной выборке достигнута на **11-й эпохе** и составила **77.5%**. После этого модель не улучшалась в течение 8 эпох, и обучение было прекращено.

Финальная точность на тестовой выборке (после восстановления лучших весов): 77.50%.




рис 2 – график точности & функции потерь на обучении и валидации по эпохам

4. Заключение

В ходе лабораторной работы была реализована полная цепочка обработки ЭЭГ-сигналов для распознавания воображаемых движений. Ключевые достижения:

1. **Успешное применение вейвлет-преобразования** (CWT с вейвлетом Morlet) позволило преобразовать одномерные временные ряды в информативные двумерные скалограммы, сохраняющие как временную, так и частотную локализацию.
2. **Построена и обучена свёрточная нейронная сеть** с двумя свёрточными слоями, Dropout и полносвязными слоями. Несмотря на большое количество параметров (49 млн), регуляризация помогла избежать сильного переобучения.
3. **Получена итоговая точность 77.5%** на тестовой выборке, что значительно выше случайного угадывания (50%) и подтверждает способность модели выделять значимые паттерны, связанные с двигательным воображением.

Недостатки и направления улучшения:

- Большое число параметров из-за полносвязного слоя после Flatten (384 000 входов). Рекомендуется заменить Flatten на `GlobalAveragePooling2D` или добавить дополнительный пулинг по времени.

- Устаревшее обращение к вейвлету `smor` (без параметров) вызвало предупреждение; в будущем следует использовать явный формат `smorB-C` (например, `smor1.0-0.5`).
- Можно экспериментировать с разными диапазонами масштабов и другими материнскими вейвлетами (например, `mech`, `db4`).

В целом, предложенный подход демонстрирует высокую эффективность и может быть рекомендован для дальнейших исследований в области интерфейсов «мозг–компьютер».