



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н. Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н. Э. Баумана)

ФАКУЛЬТЕТ ИУ «Информатика, искусственный интеллект и системы управления»

КАФЕДРА ИУ-1 «Системы автоматического управления»

ОТЧЕТ
по лабораторной работе №.5

Дисциплина: Эргатические системы

Студент ИУ1И-41М
(Группа)

31 / 03 /2026
(Подпись, дата)

Чжан Хаотянь
(И.О. Фамилия)

Преподаватель

/ /2026
(Подпись, дата)

Кучин А. С.
(И.О. Фамилия)

2026 г.

1. Цель работы

Цель данного эксперимента — Исследовать когнитивные характеристики мозга на основе сигналов электроэнцефалографии (ЭЭГ) и разработать алгоритм машинного обучения для распознавания представлений о движении (воображаемое сжатие левого или правого кулака).

Ссылка на репозиторий Git:

<https://github.com/youbadbad2agt/Haotian-Zhang/tree/Machinelearning>

2. Этапы эксперимента и анализ результатов

1. Предварительная обработка сигналов (Препроцессинг)

Необработанные сигналы ЭЭГ содержат большое количество низкочастотных артефактов (например, движения глаз, моргание). Для их устранения был применен **полосовой фильтр Баттерворта (8–30 Гц)**. Этот диапазон был выбран целенаправленно, так как именно в нем лежат Мю- (8–12 Гц) и Бета-ритмы (13–30 Гц), отвечающие за моторное воображение. Далее, для защиты от аномальных пиков и выбросов, вместо стандартной Min-Max нормализации была применена **Z-Score нормализация** по каждому из каналов.

2. Генерация изображений (Вейвлет-преобразование)

После очистки данных к трем каналам ЭЭГ (аналог RGB) было применено непрерывное вейвлет-преобразование с использованием вейвлета Морле (шкалы от 1 до 40 Гц).

Анализ: Как видно на полученном графике *"Filtered & Robust CWT Image (Sample 0, Channel C3)"*, благодаря предварительной фильтрации изображение не перекрывается фоновым шумом. Скалограмма четко отображает распределение энергии во времени и частоте. На вход нейронной сети был передан тензор размерностью (400, 40, 1000, 3).

3. Обучение сверточной нейронной сети (2D-CNN)

Спроектирована легковесная архитектура 2D-CNN с двумя сверточными блоками. Учитывая малый размер обучающей выборки (400 эпох), в сеть были интегрированы механизмы жесткой регуляризации: слои BatchNormalization и Dropout (0.6). Использовалась функция потерь `binary_crossentropy` и алгоритм ранней остановки (Early Stopping).

4. Анализ результатов

Модель была протестирована на независимой выборке из 320 записей.

Итоговая точность (Test Accuracy): 70.94%

5. 测试集最终评估与可视化...


```
=====
✅ 最终测试集准确率 (Test Accuracy): 70.94%
=====
```

```
10/10 [=====] - 0s 38ms/step
```

分类评估报告:

	precision	recall	f1-score	support
想象左手 (0)	0.68	0.78	0.73	160
想象右手 (1)	0.74	0.64	0.69	160
accuracy			0.71	320
macro avg	0.71	0.71	0.71	320
weighted avg	0.71	0.71	0.71	320


Кривые обучения (Accuracy / Loss): Графики показывают здоровый процесс обучения. Кривая потеря на валидации (Val Loss) стабилизируется вслед за тренировочной, не демонстрируя резкого экспоненциального роста. Это доказывает, что механизм Dropout успешно подавил переобучение.



Матрица ошибок (Confusion Matrix):

Из 160 случаев представления движения **левой рукой**, модель верно распознала **125**, ошибившись 35 раз.

Из 160 случаев представления движения **правой рукой**, модель верно распознала **102**, ошибившись лишь 58 раз.



Модель лучше распознает паттерны левой руки (чувствительность 78%), чем правой (чувствительность 64%). Тем не менее, общая точность в ~71% является надежным доказательством того, что 2D-CNN успешно извлекает пространственно-временные признаки из вейвлет-скалограмм, очищенных от низкочастотных артефактов.

3. Заключение

Эксперимент признан **полностью успешным**. Поставленная задача классификации временных рядов ЭЭГ для определения когнитивных характеристик выполнена.

Эффективность подхода: Трансформация одномерного сигнала в 2D-изображение с помощью SWT в связке с алгоритмами компьютерного зрения (2D-CNN) доказала свою состоятельность. Сеть успешно научилась выявлять пространственно-временные паттерны снижения энергии (десинхронизацию мю-ритма, ERD), возникающие при мысленном представлении движения.

Важность фильтрации: Эксперимент наглядно продемонстрировал, что для зашумленных данных ЭЭГ предобработка (полосовая фильтрация 8-30 Гц и Z-нормализация) является критически важной. Именно она позволила извлечь полезный сигнал и достичь точности классификации почти в 80% на относительно небольшом наборе данных.

Перспективы: Полученная точность в **70.94%** является отличным базовым показателем для бинарного нейроинтерфейса. Для дальнейшего повышения точности возможна интеграция алгоритмов пространственной фильтрации (например, CSP - Common Spatial Pattern) перед подачей данных в CNN.