



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н. Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н. Э. Баумана)

ФАКУЛЬТЕТ ИУ «Информатика, искусственный интеллект и системы управления»

КАФЕДРА ИУ-1 «Системы автоматического управления»

ОТЧЕТ

Исследование когнитивных характеристик мозга по данным ЭЭГ по лабораторной работе №.5

Дисциплина: Эргатические системы

Студент ИУ1И-41М
(Группа)

16 / 05 /2026
(Подпись, дата)

Чжан Чжиян
(И.О. Фамилия)

Преподаватель

/ /2026
(Подпись, дата)

Кучин А. С.
(И.О. Фамилия)

2026 г.

1. Цель работы

Исследование частотно-временных характеристик сигналов ЭЭГ с помощью непрерывного вейвлет-преобразования (CWT) и построение сверточной нейронной сети (CNN) для автоматизированной бинарной классификации состояний моторного воображения (определение представления о сжатии левого или правого кулака).

Отработайте рабочий процесс управления версиями: создайте папку проекта lab5 и полностью внедрите рабочий процесс Git от написания кода локально до внесения изменений в удаленный репозиторий GitHub.

Ссылка на репозиторий Git:

<https://github.com/CAICAIWOSHISHEIY/Machine-Learning-Labs/blob/main/lab5.ipynb>

2. Методика исследования и описание алгоритма

Описание набора данных: В данной работе исследование проводилось на основе фрагментов базы данных *PhysioNet EEG Motor Movement/Imagery Dataset*. Обучающая выборка содержит 400 сигналов ЭЭГ (размерность матрицы признаков составляет 400×3000 , где 3000 — количество временных отсчетов), а тестовая выборка включает в себя 320 аналогичных сигналов (320×3000). Частота дискретизации исходных данных составляет 160 Гц. Целевые метки представляют собой бинарные классы: класс 0 соответствует воображаемому сжатию левого кулака, а класс 1 — воображаемому сжатию правого кулака.

Частотно-временное преобразование (CWT):

Поскольку сигналы ЭЭГ являются высокошумными и нестационарными во времени, их прямой анализ во временной области малоэффективен. Для извлечения информативных признаков было применено непрерывное вейвлет-преобразование (Continuous Wavelet Transform, CWT). В качестве материнского вейвлета использовался комплексный вейвлет Морле (Complex Morlet wavelet, 'cmor1.5 – 1.0'), который традиционно считается наиболее эффективным

базисом для анализа биоэлектрической активности мозга благодаря оптимальному соотношению неопределенности времени и частоты.

Диапазон вейвлет-масштабов (scales) был установлен от 1 до 31. Данный диапазон при частоте дискретизации 160 Гц позволяет детально отобразить частотно-временную динамику энергии в области сенсомоторных ритмов головного мозга, а именно:

- **Мю-ритм (8–12 Гц)**
- **Бета-ритм (13–30 Гц)**

Именно эти ритмы претерпевают характерные изменения (явления десинхронизации и синхронизации, ERD/ERS) в моторной коре во время воображения движений конечностей. В результате выполнения CWT каждый одномерный временной ряд длиной 3000 отсчетов преобразуется в двумерную матрицу спектральной плотности — скалограмму (scalogram) размером $31 * 3000$. Для подачи в сверточную нейронную сеть данные матрицы рассматриваются как одноканальные серые изображения (размерность тензора: $[1, 31, 3000]$).

Архитектура сверточной нейронной сети (CNN):

Для автоматического распознавания пространственно-временных паттернов на полученных скалограммах была разработана специализированная архитектура глубокой сверточной нейронной сети. Архитектура сети оптимизирована для работы с вытянутыми вейвлет-картами и состоит из следующих функциональных блоков:

1. Первый блок экстракции признаков:

●Сверточный слой (*Conv2d*): 1 входной канал (скалограмма), 16 выходных каналов (карт признаков), размер ядра свертки $3 * 3$, заполнение *padding* = 1. Слой извлекает базовые локальные частотно-временные паттерны.

- Слой пакетной нормализации (*BatchNorm2d*): стабилизирует распределение активаций, ускоряет сходимость сети и снижает зависимость от начальной инициализации весов.

- Функция активации (*ReLU*): вводит нелинейность в модель.

- Слой максимального пулинга (*MaxPool2d*): размер ядра $2 * 2$. Выполняет пространственную дискретизацию, уменьшая размерность карт признаков в два раза и обеспечивая инвариантность к малым сдвигам.

2. Второй блок экстракции признаков:

- Сверточный слой (*Conv2d*): 16 входных каналов, 32 выходных канала, размер ядра $3 * 3$, $padding = 1$. Позволяет формировать более сложные, высокоуровневые комбинации признаков.

- Слой пакетной нормализации (*BatchNorm2d*) и функция активации (*ReLU*).

- Слой максимального пулинга (*MaxPool2d*): размер ядра $2 * 2$.

3. Блок адаптивного агрегирования:

- Слой адаптивного среднего пулинга (*AdaptiveAvgPool2d*): преобразует карты признаков к фиксированному пространственному размеру $8 * 8$. Использование данного слоя критически важно, так как оно гарантирует независимость архитектуры классификатора от длины исходной временной последовательности и полностью исключает ошибки рассогласования размерностей (Dimension Mismatch) при переходе к полносвязным слоям.

4. Полносвязный классификатор:

- Операция выравнивания (*Flatten*): преобразует двумерные карты признаков в одномерный вектор размерностью $32 * 8 * 8 = 2048$ элементов.

- Первый полносвязный слой (*Linear*): 2048 входных нейронов, 128 выходных нейронов с функцией активации *ReLU*.

- Слой регуляризации (*Dropout*): со значением вероятности 0.5. Данный слой случайным образом отключает половину нейронов в процессе обучения на

каждой эпохе, что предотвращает коадаптацию весов и является мощным средством подавления эффекта переобучения (overfitting).

- Выходной полносвязный слой (*Linear*): 128 входных нейронов, 1 выходной нейрон.

- Выходная функция активации (*Sigmoid*): отображает выходное значение сети в диапазон $[0, 1]$, интерпретируемый как апостериорная вероятность принадлежности сигнала к классу 1 (воображение движения правой руки).

Название слоя	Размер входного тензора	Параметры слоя	Размер выходного тензора
Input	(Batch, 1, 31, 3000)		(Batch, 1, 31, 3000)
Conv2d_1 + BN + ReLU	(Batch, 1, 31, 3000)	Kernel: 3 * 3, Channels: 16	(Batch, 1, 16, 31, 3000)
MaxPool2d_1	(Batch, 16, 31, 3000)	Kernel: 2 * 2	(Batch, 16, 15, 1500)
Conv2d_2 + BN + ReLU	(Batch, 16, 15, 1500)	Kernel: 3 * 3, Channels: 32	(Batch, 32, 15, 1500)
MaxPool2d_2	(Batch, 32, 15, 1500)	Kernel: 2 * 2	(Batch, 32, 7, 750)
AdaptiveAvgPool2d	(Batch, 32, 7, 750)	Target Size: 8 * 8	(Batch, 32, 8, 8)
Flatten	(Batch, 32, 8, 8)		(Batch, 2048)
Linear_1 + ReLU	(Batch, 2048)	Neurons: 128	(Batch, 128)
Dropout	(Batch, 128)	Probability: 0.5	(Batch, 128)
Linear_2 + Sigmoid	(Batch, 128)	Neurons: 1	(Batch, 1)

3. Анализ результатов

Процесс обучения и сходимость модели: Обучение разработанной сверточной нейронной сети проводилось в течение 25 эпох с использованием оптимизатора Adam (параметр скорости обучения $lr = 0.001$) и функции потерь бинарной кросс-энтропии (*BCELoss*). На начальном этапе (эпоха №1) величина потерь составляла 0.7462, а точность классификации на обучающей выборке находилась

на уровне случайного угадывания — 51.25%. В процессе оптимизации весов сети графики продемонстрировали стабильную и плавную сходимость алгоритма. К финальной 25-й эпохе функция потерь на обучающей выборке успешно снизилась до значения 0.5320, а точность (Training Accuracy) достигла 72.75%. Отсутствие резких скачков и осцилляций на кривой потерь свидетельствует о правильно подобранном шаге градиентного спуска.




Рис. 1. Кривые обучения нейросети: график функции потерь (Loss) и график точности (Accuracy) на обучающей выборке.

Анализ качества классификации на тестовой выборке:

Для объективной оценки обобщающей способности (генерализации) обученной модели было проведено тестирование на независимой выборке, содержащей 320 сигналов, которые не участвовали в процессе оптимизации весов. Итоговая точность классификации на тестовом наборе данных (Test Accuracy) составила 80.94%. Тот факт, что точность на тестовых данных оказалась выше, чем на обучающих, подчеркивает высокую эффективность примененного слоя регуляризации Dropout(0.5), который предотвратил коадаптацию признаков и жестко подавил эффект переобучения (overfitting).

Для более глубокого метрического анализа бинарной классификации моторного воображения («левый кулак» против «правого кулака») была построена ROC-кривая (кривая ошибок) и рассчитана площадь под ней (метрика AUC). Полученное значение AUC-ROC составило 0.7960.

График ROC-кривой уверенно стремится к левому верхнему углу координатной плоскости, существенно отклоняясь от диагональной линии случайного классификатора ($AUC = 0.5$). Это количественно подтверждает высокую разделительную способность модели: разработанная система способна с высокой надежностью дифференцировать паттерны ЭЭГ, соответствующие различным типам когнитивной активности человека, независимо от выбранного порога отсечения вероятности.




Рис. 2. ROC-кривая классификации состояний моторного воображения на тестовой выборке.

Физиологический и частотно-временной анализ скалограмм: Анализ двумерных карт спектральной плотности (скалограмм), полученных с помощью

вейвлет-преобразования Морле, позволяет связать математические результаты нейросетевого моделирования с реальными нейрофизиологическими процессами.




Рис. 3. Пример частотно-временной скалограммы сигнала ЭЭГ (комплексный вейвлет Морле) для класса воображаемого сжатия кулака.

На репрезентативной скалограмме (Рис. 3) отчетливо наблюдаются локализованные во времени области модуляции энергии (интенсивные цветовые пятна в красно-оранжевом спектре), сосредоточенные на масштабах, соответствующих низкочастотным мю- (8–12 Гц) и бета- (13–30 Гц) ритмам головного мозга. Данные энергетические флуктуации отражают феномены десинхронизации и синхронизации, связанные с событием (ERD/ERS), которые генерируются моторной корой при мысленном представлении движения конечности.

Поскольку CWT преобразовало хаотичный одномерный временной ряд в высококонтрастное двумерное изображение, где паттерны ERD/ERS стали пространственно выраженными, сверточные слои сети (Conv2d) смогли эффективно извлечь инвариантные признаки фильтрации энергии. Это подтверждает, что связка методов непрерывного вейвлет-анализа и глубокого сверточного обучения является оптимальным и физиологически обоснованным подходом для задач декодирования команд в интерфейсах мозг-компьютер (BCI).

4. Заключение

В ходе выполнения лабораторной работы были сделаны следующие выводы:

1. **Эффективность вейвлет-анализа:** Применение непрерывного вейвлет-преобразования (CWT) на основе комплексного вейвлета Морле (*Complex Morlet*) доказало свою высокую эффективность при работе с нестационарными биоэлектрическими сигналами. Перевод одномерных временных рядов ЭЭГ в двумерные скалограммы позволил успешно локализовать во времени и частоте флуктуации энергии сенсомоторных ритмов (μ – и β – ритмов), сделав скрытые когнитивные паттерны моторного воображения доступными для пространственного анализа сверточными слоями.

2. **Робастность архитектуры нейросети:** Разработанная модель сверточной нейронной сети (CNN) продемонстрировала высокую структурную стабильность и устойчивость к обучению. Использование слоя адаптивного пулинга (*AdaptiveAvgPool2d*) обеспечило независимость классификатора от длины входной последовательности, а интеграция механизма регуляризации *Dropout* с коэффициентом 0.5 позволила эффективно подавить эффект переобучения (*overfitting*), обеспечив сглаженный характер кривых потерь и точности.

3. **Практическая ценность и результативность:** Достигнутая итоговая точность классификации на независимой тестовой выборке, равная 80.94%, в сочетании со значением метрики AUC-ROC (0.7960), количественно подтверждает отличную обобщающую способность и высокую разделительную силу разработанного классификатора. Созданная система надежно дифференцирует мысленные команды («левый кулак» против «правого кулака»), полностью удовлетворяет жестким требованиям к качеству распознавания состояний человека-оператора и имеет высокую практическую ценность для построения неинвазивных интерфейсов мозг-компьютер (BCI).